

基于随机图的 Floyd-Warshall 算法运行分析

北京市陈经纶中学 杨熙坤

摘要

Floyd-Warshall 算法是图论中最重要的算法之一，其可以解决结点对之间的最短路径问题。松弛 (relaxation) 操作是 Floyd-Warshall 的重要步骤之一，对于不同的图，松弛操作的操作次数也不同。本文假定一张图是随机的，其中所有边的权重均服从正态分布，即边权重 w 的取值满足如下概率密度分布函数：

$$P(w = x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

并且依此假定，计算了算法进行松弛操作次数的期望：

$$n_0 = \frac{N^3}{2} \operatorname{Erfc}\left(\frac{\mu}{\sqrt{6}\sigma}\right) = \Theta(N^3)$$

同时，本文还得到了一个常数，

$$C = \frac{1}{2} \operatorname{Erfc}\left(\frac{\mu}{\sqrt{6}\sigma}\right)$$

此常数和算法运行效率正相关，由此，本文证明了算法处理权重分散的图比处理权重集中的图更慢。

关键词

图论、Floyd-Warshall、最短路径、正态分布、松弛 (relaxation)、数学期望、常数分析

基于随机图的 Floyd-Warshall 算法运行分析

北京市陈经纶中学 杨熙坤

一、引入

考虑如下场景，一张图 $G = (N, M)$ ，其中 N 是结点数 (node)， M 是边数。在存储图 G 时，我们需要一张 $N \times N$ 的矩阵 G 。最开始时， G_{ij} 表示结点 $i \rightarrow j$ 的边的权重。

我们希望在本文解决一个问题：在最开始 G_{ij} 服从正态分布 ($G_{ij} \sim N(\mu, \sigma^2)$, $\mu > 0$) 时，整个算法的松弛操作应该进行多少次（松弛次数的期望）。

对于任意一边 $i \rightarrow j$ ，其权重概率密度函数表示为：

$$P(G_{ij} = x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

由于负权重不存在，我们可以估算：

$$\int_0^{+\infty} P(G_{ij} = x) dx \approx \int_{-\infty}^{+\infty} P(G_{ij} = x) dx = 1$$

在最初状态， G_{ij} 表示边的权重，如果不存在此条边，可认为 $G_{ij} = \infty$ 。注意，在运行 **Floyd-Warshall** 算法时， G_{ij} 将表示从结点 i 到结点 j 的路线值，其是不断刷新的，在算法运行结束之后， G_{ij} 表示从结点 i 到结点 j 的最短路线值。

二、Floyd Warshall 算法的原理

Floyd-Warshall 的本质是动态规划 (dynamic programming)，其拟定图 G 中一个中间结点 k ($k \in \{1, 2, \dots, N\}$)，查看 $i \rightarrow j$ 的路线能否因为经过 k 而变得更短，即能否满足三角不等式：

$$G_{ij} > G_{ik} + G_{kj}$$

如果可以，那么其将赋值 $G_{ij} = G_{ik} + G_{kj}$ ，这个操作称为松弛 (relaxing)。对于每个松弛操作，可以认为复杂度为 $O(1)$ 。

具体来讲，其算法思路（伪代码）为：

```
for k = 1 to N
  for i = 1 to N
    for j = 1 to N
      G[i][j] = min(G[i][k] + G[k][j])
```

三、 $k = 1$ 循环的分析

对于中间节点 $k = 1$ ，其所有边尚未完成松弛，三角不等式判定为：

$$G_{ij} > G_{i1} + G_{1j}$$

我们需要求解此三角不等式成立的概率。首先将不等式写为：

$$G_{ij} - G_{i1} - G_{1j} > 0$$

我们定义 $H := G_{ij} - G_{i1} - G_{1j}$ 。由于 $G_{ij}, G_{i1}, G_{1j} \sim N(\mu, \sigma^2)$ ，即：

$$\begin{cases} \mathbb{E}G_{ij} = \mathbb{E}G_{i1} = \mathbb{E}G_{1j} = \mu \\ \mathbb{D}G_{ij} = \mathbb{D}G_{i1} = \mathbb{D}G_{1j} = \sigma^2 \end{cases}$$

根据期望和方差的运算关系

$$\begin{cases} \mathbb{E}(aX + bY) = a\mathbb{E}X + b\mathbb{E}Y \\ \mathbb{D}(aX + bY) = a^2\mathbb{D}X + b^2\mathbb{D}Y \end{cases}$$

可得到

$$\begin{cases} \mathbb{E}H = \mu - \mu - \mu = -\mu \\ \mathbb{D}H = \sigma^2 + \sigma^2 + \sigma^2 = 3\sigma^2 \end{cases}$$

根据正态分布的性质，我们可以得到

$$\mathbb{P}(H > 0) = \int_0^{+\infty} \frac{1}{\sigma\sqrt{6\pi}} \exp\left(-\frac{(x+\mu)^2}{6\sigma^2}\right) dx$$

借助误差分析函数中的Erfc函数，我们可以得到，

$$\mathbb{P}(G_{ij} > G_{i1} + G_{1j}) = \mathbb{P}(H > 0) = \frac{1}{2} \text{Erfc}\left(\frac{\mu}{\sqrt{6}\sigma}\right)$$

因此对于 $N \times N$ 的图，在第一次 k 循环中，松弛次数的期望 $\mathbb{E}[\text{times of relaxation}, k = 1]$ 为：

$$\mathbb{E}[\text{times of relaxation}, k = 1] = \frac{N^2}{2} \text{Erfc}\left(\frac{\mu}{\sqrt{6}\sigma}\right)$$

¹ 成立的前提是 $\text{Re}[\sigma^2] > 0$ 和 $\text{Re}[\mu] > 0$ 。根据假设，这两个条件都符合。

² $\text{Erfc}(\cdot)$ 定义为 $\text{Erfc}(\cdot) := 1 - \text{Erf}(\cdot)$ ，其中 $\text{Erf}(\cdot)$ 是误差函数，定义为

$$\text{Erf } z = \frac{2}{\sqrt{\pi}} \int_0^z e^{-t^2} dt$$

在正态分布中， $N(\mu, \sigma^2)$ 的概率密度分布函数为：

$$\frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

概率累计分布函数为：

$$\int_{-\infty}^{+\infty} \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) dx = \frac{1}{2} \left(1 + \text{Erf}\left(\frac{x-\mu}{\sqrt{2}\sigma}\right)\right)$$

四、 $k = 2$ 循环的分析

我们首先需要确定，对于边 $i \rightarrow j$ ，经过松弛操作 $G_{ij} = G_{ik} + G_{kj}$ 之后， G_{ij} 的概率密度分布是什么样子的。

由于分布函数和具体取值无关，以及第三节所指出的期望、方差运算方法，不难看出经过松弛后， G_{ij} 的期望为 2μ ，方差为 $2\sigma^2$ ，因此概率密度分布为

$$P(G_{ij} = x) = \frac{1}{\sigma\sqrt{4\pi}} \exp\left(-\frac{(x-\mu)^2}{4\sigma^2}\right)$$

由于在上一步获得松弛的概率为

$$P(G_{ij} > G_{i1} + G_{1j}) = \frac{1}{2} \operatorname{Erfc}\left(\frac{\mu}{\sqrt{6}\sigma}\right)$$

所以

$$P(G_{ij} = x) = \begin{cases} \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), & P = 1 - \frac{1}{2} \operatorname{Erfc}\left(\frac{\mu}{\sqrt{6}\sigma}\right) \\ \frac{1}{\sigma\sqrt{4\pi}} \exp\left(-\frac{(x-\mu)^2}{4\sigma^2}\right), & P = \frac{1}{2} \operatorname{Erfc}\left(\frac{\mu}{\sqrt{6}\sigma}\right) \end{cases}$$

根据全概率公式， $P(G_{ij} = x)$ 可以继续化简：

$$\begin{aligned} P(G_{ij} = x) &= \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \left(1 - \frac{1}{2} \operatorname{Erfc}\left(\frac{\mu}{\sqrt{6}\sigma}\right)\right) \\ &\quad + \frac{1}{\sigma\sqrt{4\pi}} \exp\left(-\frac{(x-\mu)^2}{4\sigma^2}\right) \left(\frac{1}{2} \operatorname{Erfc}\left(\frac{\mu}{\sqrt{6}\sigma}\right)\right) \\ &= \frac{1}{\frac{2\sqrt{2}}{2\sqrt{2} + \left(\exp\left(\frac{(x-\mu)^2}{4\sigma^2}\right) - \sqrt{2}\right) \operatorname{Erfc}\left(\frac{\mu}{\sqrt{6}\sigma}\right)} \cdot \sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \end{aligned}$$

我们针对

$$L := \frac{2\sqrt{2}}{2\sqrt{2} + \left(\exp\left(\frac{(x-\mu)^2}{4\sigma^2}\right) - \sqrt{2}\right) \operatorname{Erfc}\left(\frac{\mu}{\sqrt{6}\sigma}\right)}$$

绘制函数 $L - x$ 的函数图像。见 Fig 1,2。




Fig 1,2. $x \in (0,100)$ 和 $x \in (0,1\ 000)$ 时的 $L-x$ 图。两张图均选择了 $\mu = x_{\max}/2$, $\sigma = 2.5$ 。事实上,不同的 μ, σ 对图像影响不大。可以认为在一般的图中, $L = 1$ 。

误差允许, 在算法分析中, 我们可以直接选择

$$L \approx 1$$

即:

$$P(G_{ij} = x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

因此 G_{ij} 在松弛后仍满足 $G_{ij} \sim N(\mu, \sigma^2)$ 。

根据第三节的计算, $k = 2$ 循环松弛次数的期望为:

$$E[\text{times of relaxation}, k = 2] = \frac{N^2}{2} \text{Erfc}\left(\frac{\mu}{\sqrt{6}\sigma}\right)$$

五、 $3 \leq k \leq N$ 循环的分析

我们在三、四节确定了如下结论:

1. 不论如何松弛, 任意一条边 $i \rightarrow j$ 的权重均满足 $G_{ij} \sim N(\mu, \sigma^2)$;
2. 任意一次 k 循环, 进行松弛操作的期望次数均为

$$n = \frac{N^2}{2} \text{Erfc}\left(\frac{\mu}{\sqrt{6}\sigma}\right)$$

这在往后的循环中依然适用。

六、结论

因此，Floyd-Warshall 运行完成后，其进行松弛操作的总期望次数为：

$$n_0 = Nn = \frac{N^3}{2} \operatorname{Erfc} \left(\frac{\mu}{\sqrt{6}\sigma} \right)$$

Floyd-Warshall 算法的本身时间复杂度为 $\Theta(N^3)$ ，本论文证明了其松弛操作的运行次数也为 $\Theta(N^3)$ 。

七、常数分析

我们注意到存在一个常数

$$C = \frac{1}{2} \operatorname{Erfc} \left(\frac{\mu}{\sqrt{6}\sigma} \right)$$

是本文分析的产物。其不会决定算法的渐进复杂度，但是在 N 较大时仍会影响算法的运行。

根据 Erf 函数的性质，可知 Erfc 函数是减函数，因此 $\mu\sigma^{-1}$ 的值越大越利于算法的运行。在保证 μ 稳定的情况下， σ 越大，即边权重值越分散，算法运行效率越低；反之， σ 越小，即边权重值越集中，算法运行效率越高。

参考文献

- [1] Thomas H. Cormen, Charles E. Leiserson, Ronald L. Rivest, Clifford Stein. *Introduction to Algorithms*. 3rd Edition.
- [2] Normal distribution. Wikipedia
- [3] Error function. Wikipedia